

Corrigé : Vision Desk

ViT, JSON et MCP grounded

Computer Vision in Finance — Master 2 Finance, Data et IA

Dhiya Lecheheb

2026

1 Lecture du corrigé

Ce document répond à la **tâche fermée** du cas avec un protocole de référence et des traces types. La section 2.1 consigne les métriques d'une exécution du notebook (**SEED=42**). Les autres F1 restent pédagogiques. Non négociable : ViT (pas LSTM), schéma JSON avant le test, quatre tools MCP, aucune affirmation inventée.

2 Labo de référence (Colab)

Notebook exécutable, aligné sur ce corrigé :

Ressource	Lien
Dépôt	github.com/Amzil-AI/Vision-desk
Notebook	<code>vision_desk_colab.ipynb</code>
Ouvrir dans Colab	colab.research.google.com/.../vision_desk_colab.ipynb

Le notebook couvre : images finance synthétiques, split par document, fine-tune de tête ViT vs baseline majorité, contrat JSON (`vision.extract`), quatre stubs MCP, plus traces grounded et refus. Les sorties de référence sont dans **lab-reference/** (ci-dessous). Les groupes peuvent remplacer les images synthétiques par leurs captures si le protocole reste identique.

2.1 Exécution enregistrée (notebook, SEED=42)

Le code du notebook Colab a été exécuté de bout en bout (CPU local, octobre 2026 ; même logique et seed que sur [Colab](#)). Les artefacts sont copiés dans le dépôt sous **lab-reference/** (`metrics.json`, `grounded_trace.json`, `refusal_trace.json`).

Métrique	Valeur (documents held-out)
Images train / val	96 / 32 (8 documents val)
F1 macro baseline majorité	0,056
F1 macro ViT-Tiny (tête, 8 epochs)	1,000
Bat la baseline ?	oui
Fichiers	<code>metrics.json</code> , <code>grounded_trace.json</code> , <code>refusal_trace.json</code>

Lecture. Un F1 macro = 1,0 sur les templates *synthétiques* est attendu : layouts propres et classes visuellement distinctes. Des captures Bloomberg / PDF réelles donneront un F1 plus bas et une matrice de confusion plus riche — un résultat négatif honnête est acceptable si le split par document et les traces MCP sont corrects.

Exemple `vision.extract` (val, avec ticker).

```
{
  "type": "candlestick_chart",
  "confidence": 0.989,
  "ticker": "AAPL",
  "fields": {"title": "candlestick_chart__doc05_p0", "period": "2024"},
  "source_tool": "vision.extract"
}
```

Réponse grounded (issue de `lab-reference/grounded_trace.json`). « `vision.classify` classe en `candlestick_chart` (score 0,989). `vision.extract` renvoie `ticker=AAPL`. `market.lookup` : Apple Inc. (USD). Je n'affirme aucun prix de clôture : aucun champ prix dans le JSON. »

Refus (issue de `lab-reference/refusal_trace.json`). « Je ne peux pas confirmer de ticker : extraction null ou `market.lookup` en échec. Je refuse d'inventer un symbole. Relancer avec un crop plus large / autre DPI. »

3 Réponse à la tâche fermée (structure)

Exigence	Ce qu'un bon groupe montre
1. Assertion vision	Classe + score via <code>vision.classify</code> ; champs via <code>vision.extract</code>
2. Justification outil	Chaque phrase cite un tool call et un champ JSON
3. Refus	Si ticker null / tool KO → refus ou relance, jamais inventer

4 Protocole retenu

Choix	Valeur
Entrée	Captures de pages / charts, 2–4 classes
Split	Par document (labo : 75 % / 25 % docs held-out ; 96 / 32 images)
Modèle	ViT-Tiny (ou Small) préentraîné + tête fine-tunée
Baseline	Classe majoritaire, ou logits sur pixels réduits (séance 1)
JSON	<code>type</code> , <code>confidence</code> , <code>ticker?</code> (nullable), <code>fields</code>
MCP	<code>vision.classify</code> , <code>vision.extract</code> , <code>market.lookup</code> , <code>knowledge.search</code>
LLM	N'affirme un fait que s'il apparaît dans un JSON d'outil

5 Schéma JSON (contrat)

```
{
  "type": "candlestick_chart",
  "confidence": 0.989,
  "ticker": "AAPL",
```

```

"fields": {
  "title": "candlestick_chart__doc05_p0",
  "period": "2024"
},
"source_tool": "vision.extract"
}

```

Même payload que l'exemple labo ci-dessus (title = stem de l'image). `ticker` peut être `null`. Un JSON invalide (champ requis manquant) est un échec pipeline même si la classe est correcte.

6 Résultats vision (ordre de grandeur attendu)

Modèle	F1 macro (held-out)	Lecture
Labo de réf. (synth.)	maj. 0,06 / ViT 1,00	Voir §2.1 ; pas une promesse prod.
Baseline majorité (données réelles)	$\approx 0,25\text{--}0,40$	Selon déséquilibre
ViT fine-tune	nettement plus haut	Si layout stable
ViT sur nouveau template	souvent en baisse	Domain shift attendu

Lecture. Si le held-out mélange des pages du même PDF que le train, le F1 est gonflé (fuite documentaire). Analogue de `train_test_split` aléatoire dans Signal Desk.

7 Trace grounded (exigences 1 + 2)

Question utilisateur. « Quel type d'image est-ce, et quel ticker apparaît ? »

Tools.

1. `vision.classify` → {class: candlestick_chart, score: 0.989}
2. `vision.extract` → JSON ci-dessus (ticker: "AAPL")
3. `market.lookup("AAPL")` → métadonnées (nom, devise) — stub OK
4. `knowledge.search("candlestick")` → glossaire court — stub OK

Réponse finale acceptable. « `vision.classify` classe l'image comme graphique en chandeliers (0,989). `vision.extract` renvoie ticker=AAPL. `market.lookup` confirme les métadonnées Apple Inc. Je n'affirme aucun prix de clôture : aucun champ prix n'est présent dans le JSON. »

8 Refus après échec d'outil (exigence 3)

Situation. `vision.extract` renvoie ticker: null (ou `market.lookup` renvoie une erreur).

Acceptable. « Je ne peux pas confirmer de ticker : l'extraction renvoie null. Je refuse d'inventer un symbole. Relancer avec un crop plus large / autre DPI. »

Inacceptable. « C'est clairement Tesla. » — aucune source tool.

9 Anti-patterns sanctionnés

- LSTM ou Conv1D sur l'image « parce que deep learning » ;
- affirmation LLM sans tool call ;
- appeler `vision.*` puis ignorer le JSON ;
- présenter un glossaire RAG comme une extraction OCR ;
- tools d'écriture / mutation dans le labo (MCP en lecture seule uniquement).

10 Limites types (à recopier dans la note 4 pages)

1. **Layout shift** — nouveau template $\Rightarrow$ chute de F1.
2. **Capture** — DPI, barre d'UI, compression JPEG.
3. **Hallucination** — le LLM complète ce que le JSON n'a pas.

11 Lien avec Signal Desk

Signal Desk	Vision Desk
Série OHLCV + LSTM	Image + ViT
Baseline naïve / coûts	Baseline classe + grounding MCP
Walk-forward	Split par document + held-out templates
Signal mort après coûts = OK	Refus après tool KO = OK

12 Ressources vidéo

- [3Blue1Brown — Attention](#) ;
- [Kilcher — ViT paper](#) ;
- [Vision Transformer in PyTorch](#) ;
- [MCP — Anthropic](#) ;
- [MCP beginners Python](#).