

# Corrigé : Vision Desk

ViT, JSON et MCP grounded

Computer Vision in Finance — Master 2 Finance, Data et IA

Dhiya Lecheheb

2026

## 1 Lecture du corrigé

Ce document répond à la **tâche fermée** du cas avec un protocole de référence et des traces types. La section 2.1 consigne les métriques d'une exécution du notebook (**SEED=42**). Les autres F1 restent pédagogiques. Non négociable : ViT (pas LSTM), schéma JSON avant le test, quatre tools MCP, aucune affirmation inventée.

## 2 Labo de référence (Colab)

Notebook exécutable, aligné sur ce corrigé :

| Ressource         | Lien                                                                                                                              |
|-------------------|-----------------------------------------------------------------------------------------------------------------------------------|
| Dépôt             | <a href="https://github.com/Amzil-AI/Vision-desk">github.com/Amzil-AI/Vision-desk</a>                                             |
| Notebook          | <code>vision_desk_colab.ipynb</code>                                                                                              |
| Ouvrir dans Colab | <a href="https://colab.research.google.com/.../vision_desk_colab.ipynb">colab.research.google.com/.../vision_desk_colab.ipynb</a> |

Le notebook couvre : images finance synthétiques, split par document, fine-tune de tête ViT vs baseline majorité, contrat JSON (`vision.extract`), quatre stubs MCP, plus traces grounded et refus. Les sorties de référence sont dans `solution/lab-reference/` (ci-dessous). Les groupes peuvent remplacer les images synthétiques par leurs captures si le protocole reste identique.

### 2.1 Exécution enregistrée (notebook, SEED=42)

Le code du notebook Colab a été exécuté de bout en bout (CPU local, octobre 2026 ; même logique et seed que sur [Colab](#)). Les artefacts sont copiés dans le dépôt sous `solution/lab-reference/` (`metrics.json`, `grounded_trace.json`, `refusal_trace.json`).

| Métrique                           | Valeur (documents held-out)                                                                    |
|------------------------------------|------------------------------------------------------------------------------------------------|
| Images train / val                 | 96 / 32 (8 documents val)                                                                      |
| F1 macro baseline majorité         | 0,056                                                                                          |
| F1 macro ViT-Tiny (tête, 8 epochs) | 1,000                                                                                          |
| Bat la baseline ?                  | oui                                                                                            |
| Fichiers                           | <code>metrics.json</code> , <code>grounded_trace.json</code> , <code>refusal_trace.json</code> |

**Lecture.** Un F1 macro = 1,0 sur les templates *synthétiques* est attendu : layouts propres et classes visuellement distinctes. Des captures Bloomberg / PDF réelles donneront un F1 plus bas et une matrice de confusion plus riche — un résultat négatif honnête est acceptable si le split par document et les traces MCP sont corrects.

Exemple `vision.extract` (val, avec ticker).

```
{
  "type": "candlestick_chart",
  "confidence": 0.989,
  "ticker": "AAPL",
  "fields": {"title": "candlestick_chart__doc05_p0", "period": "2024"},
  "source_tool": "vision.extract"
}
```

**Réponse grounded** (issue de `lab-reference/grounded_trace.json`). « `vision.classify` classe en `candlestick_chart` (score 0,989). `vision.extract` renvoie `ticker=AAPL`. `market.lookup` : Apple Inc. (USD). Je n'affirme aucun prix de clôture : aucun champ prix dans le JSON. »

**Refus** (issue de `lab-reference/refusal_trace.json`). « Je ne peux pas confirmer de ticker : extraction null ou `market.lookup` en échec. Je refuse d'inventer un symbole. Relancer avec un crop plus large / autre DPI. »

### 3 Réponse à la tâche fermée (structure)

| Exigence               | Ce qu'un bon groupe montre                                                               |
|------------------------|------------------------------------------------------------------------------------------|
| 1. Assertion vision    | Classe + score via <code>vision.classify</code> ; champs via <code>vision.extract</code> |
| 2. Justification outil | Chaque phrase cite un tool call et un champ JSON                                         |
| 3. Refus               | Si ticker null / tool KO → refus ou relance, jamais inventer                             |

### 4 Protocole retenu

| Choix    | Valeur                                                                                                                  |
|----------|-------------------------------------------------------------------------------------------------------------------------|
| Entrée   | Captures de pages / charts, 2–4 classes                                                                                 |
| Split    | Par document (labo : 75 % / 25 % docs held-out ; 96 / 32 images)                                                        |
| Modèle   | ViT-Tiny (ou Small) préentraîné + tête fine-tunée                                                                       |
| Baseline | Classe majoritaire, ou logits sur pixels réduits (séance 1)                                                             |
| JSON     | <code>type</code> , <code>confidence</code> , <code>ticker?</code> (nullable), <code>fields</code>                      |
| MCP      | <code>vision.classify</code> , <code>vision.extract</code> , <code>market.lookup</code> , <code>knowledge.search</code> |
| LLM      | N'affirme un fait que s'il apparaît dans un JSON d'outil                                                                |

### 5 Schéma JSON (contrat)

```
{
  "type": "candlestick_chart",
  "confidence": 0.989,
  "ticker": "AAPL",
```

```

"fields": {
  "title": "candlestick_chart__doc05_p0",
  "period": "2024"
},
"source_tool": "vision.extract"
}

```

Même payload que l'exemple labo ci-dessus (title = stem de l'image). `ticker` peut être `null`. Un JSON invalide (champ requis manquant) est un échec pipeline même si la classe est correcte.

## 6 Résultats vision (ordre de grandeur attendu)

| Modèle                              | F1 macro (held-out)  | Lecture                            |
|-------------------------------------|----------------------|------------------------------------|
| Labo de réf. (synth.)               | maj. 0,06 / ViT 1,00 | Voir §2.1 ; pas une promesse prod. |
| Baseline majorité (données réelles) | $\approx 0,25-0,40$  | Selon déséquilibre                 |
| ViT fine-tune                       | nettement plus haut  | Si layout stable                   |
| ViT sur nouveau template            | souvent en baisse    | Domain shift attendu               |

**Lecture.** Si le held-out mélange des pages du même PDF que le train, le F1 est gonflé (fuite documentaire). Analogue de `train_test_split` aléatoire dans Signal Desk.

## 7 Trace grounded (exigences 1 + 2)

**Question utilisateur.** « Quel type d'image est-ce, et quel ticker apparaît ? »

**Tools.**

1. `vision.classify` → {class: candlestick\_chart, score: 0.989}
2. `vision.extract` → JSON ci-dessus (ticker: "AAPL")
3. `market.lookup("AAPL")` → métadonnées (nom, devise) — stub OK
4. `knowledge.search("candlestick")` → glossaire court — stub OK

**Réponse finale acceptable.** « `vision.classify` classe l'image comme graphique en chandeliers (0,989). `vision.extract` renvoie ticker=AAPL. `market.lookup` confirme les métadonnées Apple Inc. Je n'affirme aucun prix de clôture : aucun champ prix n'est présent dans le JSON. »

## 8 Refus après échec d'outil (exigence 3)

**Situation.** `vision.extract` renvoie ticker: null (ou `market.lookup` renvoie une erreur).

**Acceptable.** « Je ne peux pas confirmer de ticker : l'extraction renvoie null. Je refuse d'inventer un symbole. Relancer avec un crop plus large / autre DPI. »

**Inacceptable.** « C'est clairement Tesla. » — aucune source tool.

## 9 Anti-patterns sanctionnés

- LSTM ou Conv1D sur l'image « parce que deep learning » ;
- affirmation LLM sans tool call ;
- appeler `vision.*` puis ignorer le JSON ;
- présenter un glossaire RAG comme une extraction OCR ;
- tools d'écriture / mutation dans le labo (MCP en lecture seule uniquement).

## 10 Limites types (à recopier dans la note 4 pages)

1. **Layout shift** — nouveau template  $\Rightarrow$  chute de F1.
2. **Capture** — DPI, barre d'UI, compression JPEG.
3. **Hallucination** — le LLM complète ce que le JSON n'a pas.

## 11 Lien avec Signal Desk

| Signal Desk                  | Vision Desk                             |
|------------------------------|-----------------------------------------|
| Série OHLCV + LSTM           | Image + ViT                             |
| Baseline naïve / coûts       | Baseline classe + grounding MCP         |
| Walk-forward                 | Split par document + held-out templates |
| Signal mort après coûts = OK | Refus après tool KO = OK                |

## 12 Ressources vidéo

- [3Blue1Brown — Attention](#) ;
- [Kilcher — ViT paper](#) ;
- [Vision Transformer in PyTorch](#) ;
- [MCP — Anthropic](#) ;
- [MCP beginners Python](#).